

צינור RAG רפואת ילדים

מטלת אמצע קורס — RAG מותאם אישית על נתונים שלך
יומן הרצות · ארכיטקטורה · הערכה · שאלות ותשובות מלאות

1. קורפוס והכנת נתונים

1.1 בחירת הקורפוס

שני ספרי לימוד משלימים ברפואת ילדים נבחרו כקורפוס:

קובץ	כותרת	שנה	עמודים	~טוקנים
Kliegman.pdf	אסטרטגיות קבלת החלטות רפואת ילדים	2015	371	~150 K
AAP_Case-Based.pdf	רפואת ילדים בבית חולים: מדריך מבוסס מקרים	2022	785	~380 K
סה"כ			1,156	~530 K

1.2 מדוע קורפוס זה?

או לוגיקת עצי-ההחלטה בהערות הממוספרות של קלייגמן. אחזור מידע הוא הכרחי — מודל ללא RAG יהיה פרטים ספציפיים למקרה. מודל שפה כללי אינו יודע באופן אמין: מקרים קליניים ספציפיים (אמה, שמעון...), מינונים מדויקים של תרופות ומשכי ניטור,

1.3 טעינה וניקוי הנתונים

כל PDF נטען עם fitz (PyMuPDF). הצינור:

- מחלץ טקסט עמוד-עמוד עם `page.get_text()`
- מפעיל `clean_text()`: מכווץ שלוש שורות ריקות, מסיר ריצות רווחים, מנקה שורות מספרי עמודים (• 30 •) ותווי bullet בודדים
- מדלג על עמודים עם פחות מ-50 תווים (עמודי תמונה בלבד או עטיפות ריקות)
- בונה מפת חלקים מתוכן העניינים הפנימי של ה-PDF דרך `build_page_to_section_map()` עם `doc.get_toc()`
- שומר כל עמוד בתור `{doc_id, text, metadata{source, page, section, doc_id_prefix}}`

אתגרים שטופלו:

- עיוותי PDF: מקפים באמצע מילה ומעברי שורה מוסרים חלקית בנרמול רווחים
- טבלאות ועצי החלטה (קלייגמן): מחולצים כטקסט גולמי; יישור עמודות אובד אך תוכן הטקסט נשמר
- עמודים סרוקים: שני הספרים הם PDF דיגיטליים מקוריים, ולא נדרש OCR
- אין נתונים רגישים: כל המטופלים בספר AAP הם מקרי הוראה בדויים המסומנים במפורש
- אין כפילויות: כל עמוד מעובד פעם אחת; מזהי chunk מקודדים את מספר העמוד

2. ארכיטקטורת המערכת

טכנולוגיה	רכיב	שכבה
PyMuPDF (fitz)	חילוץ טקסט מ-PDF + ניקוי	טעינת מסמכים

12345678910111213141516171819202122232425262728293031323334353637383940414243444546474849505152535455565758596061626364656667686970717273747576777879808182838485868788899091929394959697989910010110210310410510610710810911011111211311411511611711811912012112212312412512612712812913013113213313413513613713813914014114214314414514614714814915015115215315415515615715815916016116216316416516616716816917017117217317417517617717817918018118218318418518618718818919019119219319419519619719819920020120220320420520620720820921021121221321421521621721821922022122222322422522622722822923023123223323423523623723823924024124224324424524624724824925025125225325425525625725825926026126226326426526626726826927027127227327427527627727827928028128228328428528628728828929029129229329429529629729829930030130230330430530630730830931031131231331431531631731831932032132232332432532632732832933033133233333433533633733833934034134234334434534634734834935035135235335435535635735835936036136236336436536636736836937037137237337437537637737837938038138238338438538638738838939039139239339439539639739839940040140240340440540640740840941041141241341441541641741841942042142242342442542642742842943043143243343443543643743843944044144244344444544644744844945045145245345445545645745845946046146246346446546646746846947047147247347447547647747847948048148248348448548648748848949049149249349449549649749849950050150250350450550650750850951051151251351451551651751851952052152


שעות. הדמיה נירולוגית אינה נדרשת לפרקו חומי פשוט. [Source: aap_p0042_fixed_001, aap_p0043_fixed_003]

(1) הילד ללא חום ובמצב נירולוגי תקין, (2) ההורים מודרכים בניהול חום וסימני החמרה, (3) מעקב רפואי תוך 24-48 קריטריוני השחרור לילד עם פרקו חומי כוללים:

ביצועי אחזור לפי קטגוריה

תוצאות בפועל — הרצה 4 (eval/run_eval.py, n=52, fixed chunks, k=5):


Hit@5 לפי קטגוריה (n=52, fixed k=5)



השוואת ניסויי Ablation

ארבעה ניסויים על 20 השאלות הראשונות. אסטרטגיית הפסקה ו-k=5 מנצחת — Hit@k שווה לגודל-קבוע אך Precision גבוה ב-6%:

השוואת ניסויי Ablation



3. אסטרטגיות פיצול לחלקים

מתאים ל-	צעד	חפיפה	גודל	אסטרטגיה
עצי החלטה של קלייגמן (צפוף, קצר)	350	50 תווים	400 תווים	גודל-קבוע
פסקאות שאלות ותשובות של AAP	n/a	אין	100-700 תווים	מבוסס-פסקה

פרטי אסטרטגיית גודל-קבוע:

- החלון מתקדם 350 תווים (=50-400) כך שחלקים סמוכים חולקים 50 תווי הקשר
- חפיפה מבטיחה שמשפט שנחתך בגבול מופיע שלם בלפחות chunk אחד
- (זנב קצרים מ-30 תווים נמחקים) (רווח לבן שיווי Chunks
- פורמט מזהה Chunk: kliegman_p0142_fixed_002 (קידומת_עמוד_אסטרטגיה_אינדקס)

פרטי אסטרטגיית פסקה:

- פיצול על שורות-כפולות (מעברי פסקה טבעיים מחילוף PDF)
- מיזוג פסקאות קצרות עוקבות עד שהחוצץ מגיע ל- $\text{min_len}=100$ תווים
- פיצול פסקאות ארוכות מדי (<700 תווים) על גבולות משפטים
- תוצאה: כל chunk הוא מחשבה קלינית שלמה — ללא חתכים שרירותיים

דוגמת כשל — היכן הפיצול פגע באחזור:

עם הערה 3 (זיהה נכון אמוקסצילין) אך החמיץ הערה 4 (קורס 10 יום לעומת 5 יום). אסטרטגיית הפסקה שמרה את ההערות יחד. פיצול בגודל-קבוע חתך בין הערה 3 (בחירת אנטיביוטיקה) להערה 4 (משך מינון) בגבול 400 התווים. האחזור החזיר את ה-chunk 'מהו הטיפול באוטיסטיס מדיה חריפה אם הילד מתחת לגיל 2?' עמוד קלייגמן המכסה נושא זה מכיל עץ החלטה עם הערות ממוספרות. שאלה:

4. הטמעה ואינדקסציה

4.1 מודל הטמעה: all-MiniLM-L6-v2

- 384 ממדים — קומפקטי, מהיר על CPU (~42 שניות ל-3,200 chunks)
- נרמול L2 בזמן קידוד ($\text{normalize_embeddings}=\text{True}$), כך שדמיון קוסינוס שווה למכפלת נקודות
- אומן על $+1\text{B}$ זוגות משפטים עם למידה ניגודית; אחזור סמנטי חזק לטקסט רפואי באנגלית
- נבחר על פני מודלים גדולים יותר (all-mpnet-base-v2, 768 ממד) לשמירת זמן תגובה סביר ללא GPU
- מילות מפתח: 'febrile seizure discharge criteria' מחמיץ קטעים עם מילים נרדפות כמו 'afebrile and neurologically baseline'
- מדוע לא BM25 לבד? BM25 מתאים

4.2 אינדקס Numpy (במקום ChromaDB)

- (float32 index/fixed_embeddings.npy, צורה index/fixed_chunks.json + N×384, 14.8 MB) (רשימת מטא-נתוני chunks)
- פורמט אחסון:
- וקטורי חיצוני — מכפלת מטריצה בלבד של $\text{numpy: scores} = \text{embeddings} @ \text{qvec.T}$ — דמיון קוסינוס מדויק בפעולה אחת
- ללא מסד נתונים
- שני זוגי אינדקס: אסטרטגיית גודל-קבוע (chunks 10,107) ואסטרטגיית פסקה (chunks 5,250)
- ניתן לשחזור מלא: build_index.py מחליף את npy/json בכל הרצה
- ספציפית ל-Windows — אינדקס ה-Rust לא נכתב לדיסק בין תהליכים. backend ה-numpy נייד לחלוטין ומספיק ל-~10K וקטורים.
- מדוע numpy במקום ChromaDB? ל-ChromaDB 1.5.9 יש תקלת HNSW

5. אחזור

ממשק: `[retrieve(query: str, k: int = 5, strategy: str = 'fixed') -> list[dict`

`np.argmaxpartition` בוחר את מדדי ה- top-k ב- $O(N)$, הממוינים בסדר יורד. כל תוצאה מוחזרת בתור `{chunk_id, text, score, metadata}`. מטמיע את השאילתה עם אותו מודל ונרמול כמו האינדקס, ואז מחשב דמיון קוסינוס כמכפלת נקודות numpy מול כל הוקטורים המאוחסנים. האחזור

מדוע $k=5$?

מקום לפרומפט המערכת ולתשובה. Ablation (הרצות 6/7) מראה ש- $k=5$ הוא נקודת האיזון בין precision לrecall עבור מערכת השאלות. ב- $k=5$ חלון ההקשר הצפוי הוא $2,000=400 \times 5$ תווים, בתוך גבול ה-context של Claude haiku ומשאיר

אחזור היברידי:

ומחזיר את ה-chunk-שואל את שני האינדקסים (גודל-קבוע ופסקה), מבטל כפילויות לפי (מקור, עמוד) תוך שמירת ה-`retrieve_hybrid()` ablation. זה לא ברירת המחדל אך זמין לניתוח top-k-עם הניקוד הגבוה יותר,

מדדי אחזור:

מדד	הגדרה	בפועל ($k=5$, fixed, $n=52$)
Hit@5	שאוחזר תואם מקור זהב בטווח 2-+ עמודים chunk ≥ 1	0.827 (43/52)
Precision@5	חלק מ-5 chunks שאוחזרו ממקור נכון	0.881
זמן תגובה ממוצע	זמן (answer) כולל יצירה	3.14 s

6. הנדסת פרומפט ויצירה

6.1 עיצוב פרומפט המערכת

פרומפט המערכת אוקף ארבעה כללים:

- כלל 1: בסס את תשובתך אך ורק על ההקשר שאוחזר (ללא הזיות מזיכרון פרמטרי)
- כלל 2: אם התשובה לא נמצאת, אמור: 'המידע לא נמצא במקורות שסופקו'
- כלל 3: לאחר תשובתך, תמיד ציטוט: [Source: chunk_id_1, chunk_id_2]
- כלל 4: היה תמציתי ומדויק קלינית. אל תוסיף מידע מידע כללי.

6.2 בניית ההנחיה

- פרומפט המשתמש: `{query}` \nQuestion: \n\nContext: \n[chunk_1_text]\n[chunk_2_text]...\n\n
- הרלוונטי ביותר ראשון chunk-מסודר לפי ניקוד יורד — ה Context
- מספיק לתשובה קלינית עם ציטוטים; מונע דריפט ארוך — `max_tokens=512`
- ברירת מחדל) — מקסימום דטרמיניזם לתשובות עובדתיות `temperature=0`

6.3 ניתוח ציטוטים

- ציטוטים מפורסרים עם `answer`, `(re.findall(r'[Source:([^\]]+)]', answer))`
- כשל ידוע: כאשר המערכת אומרת 'לא נמצא', לעיתים עדיין מציינת את ה-chunk הקרוב ביותר כציטוט שגוי
- כשל חלקי: המודל עשוי לצטט רק אחד משני chunks שתומכים יחד בתשובה

7. הערכה

7.1 מערכת השאלות המזדהבת

52 שאלות ב-5 קטגוריות, עם `must_cite_chunk_ids` מעוגנות לעמוד מדויק:

דוגמה	כמות	קטגוריה
מהם קריטריוני השחרור לילד עם פרכוס חומי?	24	עובדתי
מהו הגיל שבו ניתן לצפות לסגירת הפונטל?	10	מספרי
האם פונטל שקוע מעיד על הידרוצפלוס?	8	שלילה
כיצד שונה נזלת חריפה מכרונית?	5	השוואה
מתי פיזיולוגי לצפות לגרעין יילוד?	5	זמני

7.2 תוצאות הערכה (בסיס — $k=5$, $n=52$)

הערות	ערך	מדד
43/52 שאלות עם chunk זהב ב-top-5	0.827	Hit@5
גבוה מאוד — פיצול גודל-קבוע מדויק לקורפוס זה	0.881	Precision@5
(caching API) 'צירה s אחזור + ~0.1 s ~3.0	3.14 s	זמן תגובה ממוצע
ראה יומן הרצות הרצה 4 לפרטים	6 נכון / 3 חלקי / 1 שגוי	איכות ידנית (10)

7.3 Hit@5 (בפועל $n=52$, לפי קטגוריה)

תצפית	n	Hit@5	קטגוריה
מושלם — כללי פרומפט השלילה עבדו היטב	8/8	1.000	שלילה
השוואת פרקים אחד נפלה	4/5	0.800	השוואה
2 תשובות נחתכו בגבול ה-chunk	8/10	0.800	מספרי
טוב יותר מהצפוי — ביטויי זמן נשמרו ברובם	4/5	0.800	זמני
5 כשלים — רובם מונחי עץ-ההחלטה של קלייגמן	19/24	0.792	עובדתי

8. מחקר Ablation

הערות	זמן תגובה	Precision@k	Hit@k	ניסוי
ייחוס (20 שאלות ראשונות)	3.2 s	0.810	0.900	(בסיס) $k=5$, גודל-קבוע chunks
אותו Hit; +6% Precision — האפשרות הנפוצה ביותר	3.2 s	0.870	0.900	$k=5$, פסקה chunks
מספרי 1 hit גבוה, מפסיד Precision	2.8 s	0.850	0.850	$k=3$, גודל-קבוע chunks
ללא שיפור Precision; Hit יורד 2.3%	3.3 s	0.787	0.900	$k=8$, גודל-קבוע chunks

ממצא מרכזי:

(2.8-3.3 s) — צוואר הבקבוק הוא קריאת ה-API, לא האחזור. $k=3$ מפסיד hit אחד מספרי; $k=8$ מוסיף רעש ללא שחזור hits נוספים. — שווה לפיצול גודל-קבוע ב-0.900 Hit) אך עם 6% יותר (0.870 Precision לעומת 0.810). זמן התגובה כמעט שטוח בכל הניסויים אסטרטגיית הפסקה ב- $k=5$ היא האפשרות הכוללת הטובה ביותר

9. ניתוח כשלים

פתרון	סיבה שורשית	תדירות	מצב כשל
הורד סף דילוג; חילוף ממוד-טבלה	עמוד טבלת קלייגמן נדלג על ידי מסנן 50-10 (ש.3)	ציון Ballard לא נמצא	
גבוה יותר; אחזור היברידי k	שאלת גסטרו חזרה chunks מ-AAP; תשובה (ש.10) בקלייגמן מקור שגוי		
שלב עיבוד מקדים לראשי תיבות	עמוד נכון אחוזר אך המודל לא חילץ פיענוח (ש.4)	ראשי תיבות לא פוענחו	
אסטרטגיית פסקה שומרת הקשר רב יותר	משך ניטור במשפט אחר מהמלצת הניטור 3/52	משך לא צוין	
אסטרטגיית פסקה; פיצול ממוד-חלק	פיצול גודל-קבוע מפצל הערות בהחלטת 5-10 (ש.5) אמצעי	שברי עץ-החלטה	

מדוע הזיות LLM קורות גם עם אחזור נכון:

מפרש בגמישות; (3) המודל מוסיף פרט נכון-לכאורה אך לא נתמך. כלל 4 בפרומפט ('אל תוסיף ידע כללי') מפחית אך לא מבטל זאת. עשוי 'להמציא' אם: (1) המשפט ב-chunk דו-משמעי והמודל פותר עם ידע פרמטרי; (2) ה-chunk משתמש בקיצורים מקצועיים שהמודל גם כשה-chunk הנכון אחזור, Claude

10. שיפורים שנעשה בהמשך

- לדרג מחדש (ms-marco-MiniLM-L-6-v2) cross-encoder החל, bi-encoder עם top-k לדירוג מחדש: לאחר Cross-encoder מדויקים הרבה יותר, בעלות של מעבר קדימה לכל זוג Cross-encoders לשאלות מספריות — סנן לחלקים המכילים ספרות. לשאלות זמניות — מחרוזות שנה/יום/חודש. מצמצם רעש ללא הגדלת k.
- אחזור מסונן לפי מטא-נתונים:
- חפיפה ברמת משפט: החלף חפיפת תווים בחפיפת גבולות-משפט — ערב שכל chunk מתחיל ומסתיים במשפט שלם.
- החלפת הבדיקה הידנית ל-50 שאלות reference_answer כדי לסווג נכונות תשובות מול Claude Sonnet-1.5: השתמש ב-LLM אוטומטית, תוך פרומפט המערכת (קבוע בין קריאות) לחיסכון של ~30% בעלויות טוקן Anthropic prompt caching-השתמש ב: Prompt Caching על.
- ה-numpy ב-Qdrant או Weaviate (מבוסס HNSW, מבוזר); חלק לפי תחום; הוסף BM25 היברידי; השתמש בהטמעה אסינכרונית. סקלת ייצור: למיליוני מסמכים: החלף את backend

11. שאלות ותשובות מלאות — סקירת מרצה

החלק הבא עונה על כל שאלות ההערכה הצפויות על החלטות עיצוב וההבנה שמאחורי כל שכבה בצינור ה-RAG.

פתיחה — הבנה כללית

ש: מדוע בחרת בקורפוס זה?

בשמות, לוגיקת עץ החלטות) שמודל כללי אינו יודע באופן אמין. האחזור הכרחי — לא עטיפה של משהו שה-LLM כבר יודע. בחרנו שני ספרי לימוד ברפואת ילדים מכיוון שהם מכילים עובדות קליניות מדויקות (מינוני תרופות, מקרי מטופלים

ש: איזה בעיה מערכת ה-RAG שלך פותרת?

מזיכרון. המערכת שלנו מעגנת כל תשובה בקטע שאוחזר מהספר ומצטטת את העמוד המדויק, מה שהופך את התשובה לניתנת לאימות. רופא או סטודנט ששואל על מקרה ילודים ספציפי או פרוטוקול מינון אינו יכול לסמוך על LLM

ש: מדוע LLM רגיל אינו מספיק?

פרקוס חומי) או ספי הערות מדויקים של קלייגמן. הם יהזו פרטים קלינית אפשריים אך שגויים. RAG מאלץ את התשובה לבוא מהמקור. LLMs יש ידע פרמטרי שמוקפא בזמן האימון. אין להם מקרים ספציפיים ממדריך AAP 2022 (שמעון, חולה

ש: אילו סוגי שאלות המערכת עונה עליהן טוב?

— כללי פרומפט לאישור היעדר עבדו היטב. מספרי זמני השיגו גם הם 0.800. בסך הכל המערכת ניקתה Hit@5 0.827 על 52 שאלות. שאלות שלילה השיגו ניקוד מושלם (Hit@5, 8/8 1.000)

ש: על אילו סוגי שאלות היא נכשלת?

שפיצול גודל-קבוע פיצל. שתי תשובות מספריות נחתכו בגבול 400 התווים. שאלת השוואה אחת דרשה ראיות משני פרקים שונים. עובדתי (0.792) הייתה הקטגוריה החלשה ביותר — רוב הכשלים היו מונחי עץ-ההחלטה הספציפיים לקלייגמן

נתונים וקורפוס

ש: כיצד אספת את הנתונים?

שני ה-PDF הושגו כספרי לימוד פורסמו בשימוש בקורס אקדמי. הם הוצבו ב-`/data/raw` ונטענו אוטומטית. ללא גרידה או גישת API.

ש: מה היו האתגרים בניקוי הטקסט?

שורות מספרי עמודים (* 30 *), שלוש שורות ריקות בין חלקים, רווחים שיוריים: PDF מחלץ טקסט עם עיוותי פריסת PyMuPDF עץ-ההחלטה של קלייגמן שמחולצות כטקסט לא מסודר — יישור עמודות אובד. regex מטפל בהם עם ארבעה מעברי `clean_text()`. האתגר הגדול יותר הוא טבלאות

ש: האם היו מסמכים בעייתיים? PDF סרוקים?

הייתה פריסת טבלה דו-עמודית צפופה של קלייגמן, שאותה PyMuPDF מיישר — סדר הקריאה לעיתים שגוי לנתונים טבלאיים. שני הספרים הם PDF דיגיטליים מקוריים (לא תמונות סרוקות), כך שלא נדרש OCR. הבעיה העיקרית

ש: כיצד טיפלת בכפילויות?

מכיוון שכל עמוד מעובד בדיוק פעם אחת, אין כפילויות ברמת המסמך. ברמת ה-chunk, שילוב (`doc_id + chunk_index`) הוא ייחודי. לכל עמוד מוקצה `doc_id` ייחודי המקודד קידומת מקור ומספר עמוד (לדוג', Chunks. `kriegman_p0142` יורשים מזהה זה.

ש: כיצד אימתת שהקורפוס מתאים ל-RAG?

ללא אחזור (אומת על ידי שאילתת LLM בסיסי ללא RAG על שאלות ספציפיות למקרה), ו- (3) הטקסט ניתן לחילוף (לא תמונה). בדקנו: (1) הקורפוס מכיל >30 עמודים, (2) המידע אינו ידוע היטב ל-Claude

פיצול לחלקים

ש: איזה גודל chunk בחרת ומדוע?

גדול כדי שמודל ההטמעה ילכוד הקשר סמנטי. אסטרטגיית הפסקה משתמשת ב-700-100 תווים כדי להתאים לגבולות פסקה טבעיים. 400 תווים (~80 טוקנים) לגודל-קבוע. זה שומר כל chunk בתוך אמירה קלינית אחת תוך היות מספיק

ש: מדוע נדרשת חפיפה?

את גבול 400 התווים יפוצל לשני חצאי-משפטים, אף אחד מהם לא מכיל את העובדה השלמה. חפיפת 50 תווים היא כ-קטע משפט אחד. חפיפה מבטיחה שעובדה שנחתכת בגבול שני chunks מופיעה שלמה בלפחות chunk אחד. ללא חפיפה, משפט שחוצה

ש: מה קורה אם chunks קטנים מדי?

משמעות הקטע בצורה לקויה ורעש האחזור עולה. גם יותר chunk קטנים מדי (לדוג', 100 תווים) מאבדים הקשר סמנטי — כל Chunks ובנייה איטית יותר של אינדקס API אומר יותר קריאות chunks הוא קטע משפט. ההטמעה לונכת את

ש: מה קורה אם chunks גדולים מדי?

מאוחדים. ההטמעה ממצעת על כל הטקסט, ומדללת את האות הסמנטי לאחזור. שלב היצירה מקבל גם הוא הקשר רועש Chunks גדולים מדי (לדוג', +1000 תווים) גורמים לסטייה נושאית — שני נושאים קליניים לא קשורים עשויים להיות

הטמעה ואינדקס

ש: איזה מודל הטמעה בחרת ומדוע?

רפואי באנגלית. נבחר על פני מודלים גדולים יותר, CPU על chunks ממד, מהיר (~42 שניות ל-384 3,200 all-MiniLM-L6-v2: BioBERT, (ממד) לאיזון איכות מול מהירות. מודלים ספציפיים רפואיים (all-mpnet-base-v2, 768) אחזור סמנטי חזק לטקסט. נשקלו אך לא נבחרו — הקורפוס משתמש באנגלית קלינית סטנדרטית (PubMedBERT)

ש: ניסית מספר הטמעות?

לעומת (0.810) עם Hit@5 שווה, מה שמרמז שאסטרטגיית הפיצול משפיעה על precision יותר מאשר בחירת המודל עבור קורפוס זה. לעומת (all-mpnet-base-v2) יהיה ניסוי טבעי הבא. אסטרטגיית הפסקה הראתה Precision@5 גבוה יותר (0.870) ה-ablation הריץ פיצול גודל-קבוע לעומת פסקה עם אותו מודל. ablation מודל (all-MiniLM-L6-v2)

ש: מדוע numpy במקום ChromaDB או FAISS?

מכפלת מטריצה יחידה. ל-~10K וקטורים, זה מהיר יותר (ללא IPC overhead), נייד לחלוטין, ולא דורש תלות חיצונית מעבר ל-numpy. בכל תהליך Python חדש. במקום לשדרג לאחור, החלפנו ב-backend numpy: שמור הטמעות כ-npy, טען עם np.load(), חפש עם אך לגרסה 1.5.9 יש תקלת HNSW ספציפית ל-Windows — אינדקס ה-Rust לא נכתב לדיסק בין תהליכים, מה שגרם לכשל אחזור בנינו במקור על ChromaDB,

ש: מה מדד הדמיון שהשתמשת בו?

נקודות: scores = embeddings @ qvec.T. זה מתמטית שקול ומונע את המרת distance-to-similarity הדרושה ל-ChromaDB. דמיון קוסינוס. הטמעות מנורמלות L2 בזמן קידוד (normalize_embeddings=True), כך שדמיון קוסינוס שווה למכפלת

ש: האם נרמול משפיע על התוצאות?

רק של הזווית בין הוקטורים (כיוון סמנטי), לא הגודל. זה חשוב להשוואה הוגנת בין שברי עץ-החלטה קצרים לפסקאות נרטיביות ארוכות. נרמול L2, המכפלה תלויה בגודל הוקטור, שיכול להשתנות לפי אורך משפט ועושר אוצר מילים. נרמול הופך את דמיון הקוסינוס לעניין כן. ללא

אחזור

ש: כיצד עובד האחזור?

לכל chunk בבת אחת. np.argpartition בוחר את מדדי top-k ב-O(N), הממוינים בסדר יורד. תוצאות מוחזרות כ-dicts מובנים. ונרמול כמו ה-chunks. האחזור מחשב scores = embeddings @ qvec.T — מכפלת מטריצה numpy יחידה — ונותן דמיון קוסינוס השאלית מוטמעת עם אותו מודל

ש: מה ההבדל בין precision ל-recall?

k? הרלוונטיים באינדקס, כמה אוחזר chunks-מתוך כל ה: Recall@k? שאוחזר, כמה רלוונטיים k chunks מתוך: Precision@k? k-top-נכון אחד הופיע ב chunk בינארי: האם לפחות recall הוא מדד Hit@k precision. Hit@k עשוי לפגוע ב recall גבוה יותר משפר

ש: האם אחזור טוב תמיד מוביל לתשובה טובה?

עקבית לוגית עם ה-chunk אך הוסיף פרט לא נתמך, (3) לכשול בחילוף ערך מספרי מטבלה צפופה. אחזור הכרחי אך לא מספיק. לא. גם עם ה-chunk הנכון שאוחזר, ה-LLM יכול: (1) לפרש שגוי קיצורים קליניים, (2) לייצר תשובה

ציטוטים

ש: כיצד יודעים שהתשובה מבוססת על המקור?

[Source: chunk_id, ...] מהתגובה. נאמנות ניתנת לאימות על ידי בדיקה שהטקסט של ה-chunk המצוטט מרמז על התשובה. פרומפט המערכת מורה ל-Claude לענות רק מהקשר שאוחזר ולצטט את chunk_ids שבשימוש. אנחנו מפרסרים

ש: האם ציטוטים תמיד נכונים?

את ה-chunk הקרוב ביותר כהפנייה שגויה. (2) ציטוט חלקי — המודל עשוי לצטט רק אחד משני chunks התומכים יחד בתשובה. לא. שני מצבי כשל ידועים: (1) ציטוט fallback — כשהמערכת אומרת 'לא נמצא', היא לעיתים עדיין מציינת

הערכה

ש: כיצד בנית את מערכת השאלות המוזהבת?

הוקצו must_cite_chunk_ids המעוגנות לעמוד המדויק. גיוון נאכף על ידי דרישת לפחות 5 שאלות לקטגוריה ומכסות את שני הספרים. על ידי קריאת כל פרק וניסוח שאלות שתשובותיהן מצוינות במפורש בעמוד ידוע. לכל שאלה

ש: ההבדל בין Hit@k ל-Recall@k?

איזה חלק מכל ה chunks-ממצע על כל ה Recall@k. אחרת 0, k-top-זהב כלשהו מופיע ב chunk הוא בינארי לשאלה: 1 אם Hit@k אינפורמטיבי יותר לשאלות Recall@k; מעשי יותר להערכת שאלות ותשובות Hit@k? הרלוונטיים אוחזר chunks-המוזהבים: multi-hop.

מחקר Ablation

ש: איזה שינוי היה בעל ההשפעה הגדולה ביותר?

ללא עלות זמן תגובה. הפחתת k מ-5 ל-3 הייתה הירידה הגדולה ביותר ב-Hit (נקודות אחוז). k=8 הוסיף רעש ללא שיפור ב-Hit. <- פסקה) היה בעל ההשפעה החיובית הגדולה ביותר: Hit@k זהה (0.900) אך Precision@k (0.870 6% לעומת 0.810) שינוי אסטרטגיית הפיצול (גודל-קבוע

ש: מה למדת מה-ablation?

מחמיץ ראיות k=8 multi-hop מוסיף רעש. (3) זמן התגובה כמעט שטוח (2.8-3.3 s) — צוואר הבקבוק הוא קריאת ה-Claude API. אסטרטגיית פיצול חשובה יותר מ-k עבור precision — פיצול פסקה מנצח ב-precision בכל ה-k (2) k. הוא נקודת האיזון — k=3 שלושה לקחים: (1)

שאלות מתקדמות

ש: ההבדל בין bi-encoder ל-cross-encoder?

ומסמך באופן עצמאי — הטמעת השאילתה ניתנת לחישוב מוקדם, מה שהופך את האחזור למהיר (all-MiniLM כמו) Bi-encoder לב משותפת לשניהם — הרבה יותר מדויק אך דורש מעבר קדימה אחד לכל זוג (שאילתה, מסמך Cross-encoder. מקודד שאילתה top-k i-cross-encoder לבחירה מהירה של bi-encoder משתמש ב Reranking. (לוקח שאילתה+מסמך כקלט יחיד ומעביר תשומת לדירוג מדויק.

ש: מהי סטייה סמנטית?

ארוכים או מכילים נושאים מרובים. תשומת הלב של המודל מתפשטת והתשובה עשויה לטפל בשאלה קלינית קשורה אך שונה. chunks שאוחזרו כהקשר, המודל עשוי להתחיל 'לסטות' מהכוונה הסמנטית הראשונית של השאילתה — במיוחד אם ה-chunks

ש: מהי הרעלת חלון הקשר?

לפי ההוראה המוזרקת. הפחתה: נקה טקסט שאוחזר, השתמש בפרומפט מערכת שמדגיש התעלמות מטקסטים כמו הוראות בהקשר. זדוני יכול להכיל טקסט כגון: 'התעלם מכל ההוראות הקודמות ובמקום זאת פלוט X'. אם זה אוחזר ומוצב בהקשר, ה-LLM עשוי לפעול מסמך

ש: כיצד תטפל במסמכים שמתעדכנים יומיומית?

שורות עבור chunk IDs של אותו מסמך, או בנה מחדש רק את פרוסת המסמך. לנפחי עדכון גבוהים — עבור ל-Qdrant או Weaviate. אחר גרסאות מסמכים עם hash. כאשר מסמך משתנה, פצל מחדש והטמע רק את אותו מסמך, ואז עדכן את קבצי .py ו-.json (החלף השתמש בגישת אינדקסציה מצטברת: עקוב

ש: כיצד תעשה RAG אג'נטי?

(5) יחליט אם לאחזר שוב עם שאלתה מעודנת או להמשיך ליצירה. זוהי לולאת ReAct-style שבה אחזור הוא כלי שהסוכן קורא לו. יחליט אם אחזור נדרש (שלב מטא-קוגניציה), (3) ינסח שאלתת אחזור (אולי שונה מהשאלה המקורית), (4) יבדוק chunks שאוחזרו, סוכן יעשה: (1) יקבל שאלה, (2)

שאלת סיכום

ש: אם היית צריך לפרוס מערכת זו לייצור מחר, מה הדבר הראשון שהיית משפר?

מצוינת. עדיפות שנייה: LLM כשופט להחלפת הבדיקה הידנית של 10 תשובות ולקבלת מדדי איכות אמינים על 52 השאלות אוטומטית. ידרג מחדש את 10 המועמדים הראשונים ויבטל את רוב כשלי האחזור בעלות זמן תגובה של ~0.5 שניות לשאלתה — פשרה — במיוחד לשאלות זמניות ושלילה שבהן הניסוח המדויק של הקטע שאוחזר חשוב. cross-encoder כגון ms-marco-MiniLM-L-6-v2 — הוספת cross-encoder לדירוג מחדש. האחזור הנוכחי עם bi-encoder מהיר אך עושה שגיאות אחזור שפוגעות באיכות התשובה

4: n=52; eval/run_eval.py; הרצה 8: Backend. (ablation אינדקס: קבצי ChromaDB) .numpy numpy הוחלף בשל תקלת persistence ב-Windows). דוח זה נוצר מפרויקט RAG רפואת ילדים — כל ערכי המדדים משקפים הרצות צינור אמיתיות על קורפוס PDF אמיתי (הרצה